



ZenPlanner - Report di Progetto

github.com/KekkoCoppola/ZenPlanner

Elena Carlomagno
0512119052

Francesco Coppola
0512119837

Rosaria Cervino
0512119621

March 2026

Indice

1	Scenario e Problema Analizzato	4
1.1	Contesto Applicativo	4
1.2	Problema Affrontato	4
1.3	Soluzione Proposta	4
2	Modulo 1: ZenLearner	5
2.1	Task del modulo	5
2.2	Dataset Utilizzato e Caratteristiche	5
2.2.1	Fonte e Dimensioni	5
2.2.2	Distribuzione della Variabile Target(Mental Stress Level)	5
2.2.3	Descrizione Feature Numeriche	7
2.2.4	Descrizione Feature Categorie	8
2.2.5	Feature Ingegnerizzate	9

2.3	Issue Analizzate e Soluzioni Proposte	9
2.3.1	Privacy e Compliance By Design	9
2.3.2	Gestione degli Outlier	9
2.3.3	Feature Engineering	9
2.3.4	Rimozione dei Bias e Variabili Indesiderate	11
2.3.5	Encoding Categoriale (One-Hot Encoding)	11
2.3.6	Standardizzazione e Scaling Numerico	11
2.4	Training Split	12
2.5	Modelli Confrontati	13
2.6	Analisi delle Prestazioni	16
2.6.1	Metriche di Valutazione (RMSE, MSE, MAE)	16
2.6.2	Limiti Intrinseci e Qualità Originaria del Dataset	17
3	Modulo 2: ZenScheduler	20
3.1	Task del modulo	20
3.2	Interfaccia e Dati Di Input	20
3.3	Modellazione Formale del CSP	20
3.4	Algoritmo Utilizzato	22
3.4.1	Euristiche Utilizzate	22
3.4.2	BackTracking e Validazione	24
4	Integrazione Moduli	24
4.1	Strategia di Integrazione e Architettura Logica	24
4.2	Comunicazione e Flusso dei Dati	24
4.3	Orchestrazione tramite Dashboard	25
5	Considerazioni Finali	25
5.1	Ottimizzazioni possibili	26
5.2	Sviluppi Futuri	26

Elenco delle figure

1	Distribuzione della variabile target	6
2	Matrice di Correlazione tra Feature Numeriche	8
3	SHAP Summary: Impatto delle Feature sullo Stress	10
4	Mental Stress Level by Gender	11
5	Distribuzione Feature Numeriche	12
6	Feature Importance RF classico	14
7	Feature Importance RF Tuned	14
8	Correlation Matrix di RF Tuned	15
9	Confronto Modelli con RMSE	16
10	Confronto Modelli con MSE	16
11	Confronto Modelli con MAE	17
12	Valori Reali vs Valori Predetti	18
13	Distribuzione dell'Errore	19

14	Impatto Dinamico Dei Vincoli	21
15	Influenza MRV	23
16	Influenza LCV	24

Elenco delle tabelle

1	Definizione del problema di regressione.	5
2	Statistiche generali del dataset.	5
3	Dettaglio delle feature numeriche.	7
4	Dettaglio delle feature categoriche.	8
5	Feature derivate (Feature Engineering).	9
6	Modelli confrontati.	13

1 Scenario e Problema Analizzato

1.1 Contesto Applicativo

Il contesto applicativo del progetto ZenPlanner è quello di uno "scheduler adattivo che bilancia studio e salute mentale".

Nello specifico, il sistema è progettato per:

- Massimizzare il rendimento accademico degli studenti evolvendo dinamicamente le loro sessioni di studio.
- Operare nel rispetto di specifici "vincoli di stress individuali pre-calcolati".
- Utilizzare il Machine Learning per prevedere la "resilienza cognitiva giornaliera" dell'utente.
- Affidarsi a un CSP (Constraint Satisfaction Problem) per ottimizzare l'organizzazione degli orari.

1.2 Problema Affrontato

Il progetto ZenPlanner affronta il problema di bilanciare lo studio e la salute mentale degli studenti.

Nello specifico, cerca di risolvere la difficoltà di far coesistere due obiettivi spesso in contrasto:

- Migliorare i risultati scolastici/universitari: il sistema punta a "massimizzare il rendimento accademico" evolvendo la pianificazione dello studio.
- Prevenire il burnout e il sovraccarico emotivo: lo fa organizzando il tempo "nel rispetto dei vincoli di stress individuali pre-calcolati".

In sintesi, affronta la necessità di una pianificazione didattica che non sia rigida, ma sostenibile e adattiva, capace di modificarsi giorno per giorno in base alla "resilienza cognitiva" della persona.

1.3 Soluzione Proposta

ZenPlanner è un ecosistema di pianificazione avanzata progettato per massimizzare il rendimento accademico tutelando, al contempo, il benessere psicofisico dell'utente. A differenza dei sistemi statici tradizionali, ZenPlanner impiega un'architettura ibrida che evolve dinamicamente grazie all'integrazione di Intelligenza Artificiale e Machine Learning.

L'efficacia del sistema si basa sulla sinergia di due moduli core:

- **ZenLearner:** Il motore analitico che comprende i ritmi dell'utente e le sue abitudini per predire un indice di stress mentale, tale indice fornirà allo scheduler dei vincoli per la pianificazione.

- **ZenScheduler:** Il modulo decisionale basato su Constraint Satisfaction Problems (CSP), capace di generare programmi di studio ottimizzati che rispettano vincoli temporali stringenti senza compromettere le pause rigenerative e mantenendo un indice di stress mentale dell'utente basso.

2 Modulo 1: ZenLearner

2.1 Task del modulo

Restituire un valore numerico che quantifica lo stress di uno studente in base a feature legate alle abitudini dello stesso.

Aspetto	Descrizione
Tipo	Regressione Lineare
Input	Vettore di feature numeriche
Output	Indice di resilienza cognitiva (1-10)

Tabella 1: Definizione del problema di regressione.

2.2 Dataset Utilizzato e Caratteristiche

2.2.1 Fonte e Dimensioni

Attributo	Valore
Nome	Student_Mental_Stress_and_Coping_Mechanisms
Fonte	Kaggle
Righe Originali	760
Righe Post-Processing	760
Colonne Originali	20
Feature Finali	23
Feature Utilizzate dal Modello	7

Tabella 2: Statistiche generali del dataset.


2.2.2 Distribuzione della Variabile Target(Mental Stress Level)

L a variabile target del nostro modello si presenta come un punteggio ordinale e discreto che spazia su una scala da 1 (Stress Molto Basso) a 10 (Stress Massimo).

Osservando l'intero campione di 760 studenti, emergono 3 caratteristiche fondamentali:

Distribuzione Quasi-Uniforme: A differenza delle tipiche curve a campana dove la maggior parte delle persone si concentra sui valori medi (es. 5 o 6), in questo dataset tutti i livelli di stress sono ugualmente rappresentati. Ogni singolo punteggio da 1 a 10 compare tra le 70 e le 89 volte. Non ci sono classi minoritarie o classi sovrarappresentate.

Figura 1: Distribuzione della variabile target




2.2.3 Descrizione Feature Numeriche

Feature	Descrizione	Unità
Age	Età	anni
Academic_Performance_(GPA)	Indice di performance accademica	da 0 a 5
Study_Hours_per_Week	Ore settimanali di studio	Ore
Social_Media_Usage	Ore giornaliere di utilizzo social media	Ore
Sleep_Duration	Ore di sonno a notte	Ore
Physical_Exercise	Ore settimanali di esercizio fisico	Ore
Family_Support	Supporto Familiare	da 0 a 5
Financial_Stress	Indice di stress finanziario	da 0 a 5
Peer_Pressure	Influenza dei coetani sull'individuo	da 0 a 5
Relationship_Stress	Stress da relazione	da 0 a 5
Diet_Quality	Qualità della dieta	da 0 a 5

Tabella 3: Dettaglio delle feature numeriche.

Figura 2: Matrice di Correlazione tra Feature Numeriche



2.2.4 Descrizione Feature Categoricalhe

Feature	Descrizione	Valori / Note
Counseling_Attendance	Consultazione di uno psicologo	Si/No
Stress_Coping_Mechanism	Modi in cui una persona fronteggia lo stress	Stringa
Cognitive_Distorsions	Disturbi Cognitivi	Stringa
Family_Menthel_Health_History	Anamnesi familiare di salute mentale	Stringa
Medical_Conditions	Condizioni Mediche	Stringa
Substance_use	Uso Di Sostanze Stupefacenti	Si/No

Tabella 4: Dettaglio delle feature categoriche.

2.2.5 Feature Ingegnerizzate

Feature Nuova	Logica di Creazione	Scopo
Work_Rest_Ratio	$\frac{\text{Ore di Studio}}{\text{Ore di Sonno}} \times 7$	Rapporto Studio/Sonno Settimanale
Social_Exercise_Ratio	$\frac{\text{Uso Social Media} \times 7}{\text{Esercizio Fisico} + 0.1}$	Bilanciare ore di esercizio fisico e uso social media.

Tabella 5: Feature derivate (Feature Engineering).

2.3 Issue Analizzate e Soluzioni Proposte

2.3.1 Privacy e Compliance By Design

Filtraggio etico e metodologico della storicità sanitaria L’architettura della pipeline prevede una specifica operazione di pulizia (Drop) mirata ad eliminare tutte le colonne relative allo storico medico e al profilo psicopatologico accertato dell’utente. Vengono estromesse interamente feature diagnostiche come i disturbi accertati (Medical Condition), lo storico psichiatrico familiare (Family Mental Health History), il supporto terapeutico pregresso (Counseling Attendance), le deviazioni cognitive (Cognitive Distortions) o le dipendenze (Substance Use).

2.3.2 Gestione degli Outlier

Screening e rimozione dei record estremi In questa fase esplorativa iniziale o di pulizia, i dati vengono filtrati per eliminare i record logicamente impossibili o statisticamente ”fuori scala” che potrebbero inquinare la convergenza dell’algoritmo.

Nel dataset specifico sono stati applicati filtri per limitare le ore di studio a massimo 80 a settimana e imporre un intervallo biologicamente valido per le ore di sonno notturne incluse rigidamente tra le 3 e le 14 ore. Nel dataset originale, non vi erano outlier di questo tipo, perciò i filtri sono stati inseriti a scopo preventivo per dati futuri sui quali si effettueranno predizioni.


2.3.3 Feature Engineering

Creazione di variabili derivate e indici di squilibrio Al fine di rafforzare il potere predittivo e fornire agli algoritmi correlazioni meno lineari, i dati crudi sono messi in relazione tra loro per calcolare nuove feature chimere.

Sono stati generati due indici fondamentali:

- **Work_Rest_Ratio:** calcolato dividendo il carico di ore fisse di studio per il monte ore settimanale di sonno.
- **Social_Exercise_Ratio:** l'esposizione oraria stimata ai Social Media scalata sulle ore dedicate al movimento fisico


Figura 3: SHAP Summary: Impatto delle Feature sullo Stress



2.3.4 Rimozione dei Bias e Variabili Indesiderate

Filtraggio di storicità, identificatori e metriche discriminanti Il set di dati subisce la rimozione di colonne non coerenti con l'obiettivo d'analisi (che è focalizzato esclusivamente sulle abitudini e sulle scelte di routine dello studente). Vengono scartate, in questa fase, variabili identificative o anagrafiche pure come Student ID e Gender.

Figura 4: Mental Stress Level by Gender




2.3.5 Encoding Catoriale (One-Hot Encoding)

Trasformazione matriciale del testo Le variabili categoriche testuali subiscono un processo di digitalizzazione in cui un testo specifico come "Meditation" viene spalmato su una colonna binaria autonoma Coping_Meditation valorizzata esclusivamente a 0 oppure a 1.

2.3.6 Standardizzazione e Scaling Numerico

Omogeneizzazione matematica delle metriche quantitative Tramite l'algoritmo StandardScaler, tutte le variabili numeriche continue originarie vengono modificate matematicamente in modo che il loro peso sia confrontabile ad armi pari. Assicura, ad esempio, che la quantità di ore di sonno (su base giornaliera) non venga ingiustamente soverchiato dalle 80 ore di studio dagli algoritmi che calcolano la magnitudine vettoriale.

Figura 5: Distribuzione Feature Numeriche



2.4 Training Split

Al fine di garantire l'integrità metodologica della fase di addestramento e prevenire il fenomeno dell'Overfitting, il dataset originale è stato rigorosamente partizionato in due insiemi mutuamente esclusivi sfruttando una classica ripartizione 80/20. L'80% del campione (Set di Addestramento/Training Set) rappresenta l'unica fetta di dati che gli algoritmi di Machine Learning hanno potuto "osservare"; il suo scopo esclusivo è consentire ai modelli di assimilare le relazioni logiche ed estrarre le regole matematiche e i pesi delle feature. Al contrario, il restante 20% (Set di Validazione/Test Set) è stato "segregato a monte" come hold-out prima ancora che avvenisse la fase di Scaling (per evitare perdite di informazioni, data leakage). Questo set di test funge da simulazione del mondo reale: viene presentato all'algoritmo addestrato come se fossero dati provenienti da nuovi studenti mai visti prima. Solo confrontando le previsioni fatte sul Test Set con i valori reali in esso contenuti è stato possibile valutare oggettivamente la capacità di generalizzazione dell'architettura e stabilire, i punteggi RMSE imparziali esibiti nei nostri grafici.

2.5 Modelli Confrontati

Modello	Descrizione	IperParametri
Ridge (Linear)	Regressione lineare con regolarizzazione L2	alpha=1.0
SVR	Regressione a vettori di supporto non-lineare	kernel='rbf', C=1.0, epsilon=0.1
Random Forest	Ensemble di alberi decisionali	n_estimators=100, random_state=42
XGBoost	Boosting sequenziale avanzato	n_estimators=100, objective='reg:squarederror', random_state=42
RF Tuned	Algoritmo ottimizzato sul subset di 7 feature	n_estimators=200, max_depth=10, min_samples_split=5, random_state=42

Tabella 6: Modelli confrontati.

Nota su RF Tuned Il modello Random Forest di base (configurato con l'iperparametro standard di 100 alberi e senza limiti di profondità) riceveva in pasto tutte le feature del dataset, faticando ad astrarre i pesi e mostrando prestazioni migliorabili a causa del "rumore" di fondo. Per ottimizzarlo e massimizzare il guadagno analitico, si è deciso di implementare e testare la versione Tuned. A differenza dell'approccio precedente, il Random Forest Tuned opera su due livelli di regolarizzazione: innanzitutto è stato addestrato su un subset purificato e scremato (utilizzando le sole 7 feature vitali che garantiscono l'Information Gain più alto, scartando metadati ininfluenti). In secondo luogo, i suoi iperparametri sono stati tarati per evitare l'overfitting, raddoppiando la robustezza a 200 alberi (n_estimators), imponendo un limite massimo di profondità di 10 nodi (max_depth) e uno split minimo di 5 campioni (min_samples_split). L'abbinamento di queste due tecniche ha permesso al Modello Tuned non solo di correggere gli errori del Random Forest base, ma di battere storicamente l'RMSE di tutti gli altri algoritmi lineari presenti in competizione.

Peso delle feature su RF classico e RF Tuned

Figura 6: Feature Importance RF classico






Figura 7: Feature Importance RF Tuned



Nuova Correlation Matrix L'Heatmap mostra il Coefficiente di Correlazione tra le 7 variabili fondamentali selezionate e il livello di Stress Target.

Ciò che emerge da questo grafico è proprio la bassa correlazione lineare diretta. Sull'ultima riga/colonna, che riguarda la classe target, si può notare che tutte le relazioni hanno il relativo valore numerico compreso tra -0.11 e +0.08. Questo significa che nessuna singola abitudine ha, da sola, una fortissima dipendenza matematica proporzionale con lo stress.

Figura 8: Correlation Matrix di RF Tuned



2.6 Analisi delle Prestazioni

2.6.1 Metriche di Valutazione (RMSE, MSE, MAE)

Figura 9: Confronto Modelli con RMSE




Figura 10: Confronto Modelli con MSE






Figura 11: Confronto Modelli con MAE



2.6.2 Limiti Intrinseci e Qualità Originaria del Dataset

Nonostante l'applicazione di metodologie rigorose e standardizzate nelle delicate fasi di Data Cleaning e Feature Engineering, dai risultati metrici incrociati emerge un ovvio plateau prestazionale che nessuna delle architetture testate è riuscita a valicare. È cruciale chiarire oggettivamente che questa fisiologica imprevedibilità non è in alcun modo una conseguenza o una debolezza delle pipeline di ottimizzazione e pulizia dei dati. Al contrario, l'origine del problema risiede nell'elevato grado di rumore statistico e variabilità incontrollabile insito nel dataset originario. Dal momento che la maggior parte delle istanze si basa interamente su auto-valutazioni derivate da questionari soggetti a distorsioni umane e metriche di stress altamente personali, manca una oggettività fisica lineare in molte risposte. Di conseguenza, il sistema cerca di mappare regolarità algoritmiche su fenomeni psicologici dichiarati che sono, di per sé, intrinsecamente caotici e sfumati, rendendolo un set di dati nativamente impreciso a prescindere dal livello di ingegnerizzazione applicato in fase di preprocessing.

Figura 12: Valori Reali vs Valori Predetti




Distribuzione dell'Errore Sebbene il dataset di partenza fosse distribuito uniformemente tra stress 1 e stress 10, la deformazione matematica dell'errore assume l'aspetto di un'onda o curva a campana.

Questo significa che gli errori si concentrano massicciamente intorno allo 0, confermando che nella grande maggioranza dei casi il sistema fa previsioni estremamente precise. I grossi errori sono statisticamente rari. Non vi sono quindi Bias Sistemati.

Se l'intera curva si fosse spostata verso i numeri positivi avrebbe significato che il modello prevedesse sempre "meno stress" della realtà. Poiché invece è perfettamente Centrata, possiamo certificare che il Random Forest Tuned è matematicamente imparziale: quando sbaglia una stima non sfavorisce né penalizza sistematicamente alcuna categoria di punteggio, sbagliando in egual misura in eccesso e in difetto.

Figura 13: Distribuzione dell'Errore



3 Modulo 2: ZenScheduler

3.1 Task del modulo

Assegnare sessioni di studio in slot temporali rispettando rigorosamente i vincoli imposti da **ZenLearner**.

3.2 Interfaccia e Dati Di Input

L'acquisizione dei dati in input è strutturata su due interfacce distinte:

- **Profilo Utente:** dedicata all'inserimento delle informazioni personali dell'utente. Questi dati sono categorizzati in "Dati Fisici e Accademici" e "Routine e Pressioni".
- **Generazione Piano:** deputata alla definizione dei vincoli operativi necessari per l'elaborazione del piano di studio settimanale (ad esempio, le scadenze imminenti e il monte ore dedicato a ciascuna materia).

La completa compilazione del **Profilo Utente** costituisce un prerequisito fondamentale per la fase di pianificazione. I dati raccolti in questa sezione vengono infatti elaborati dal modulo **ZenLearner** al fine di stimare un indice di resilienza cognitiva. Tale parametro, congiuntamente ai vincoli specificati dall'utente nella seconda interfaccia, viene successivamente fornito in input a **ZenScheduler**, il modulo responsabile dell'orchestrazione e della generazione finale del piano di studio.

3.3 Modellazione Formale del CSP


Questa sezione dettaglia l'architettura logica della pianificazione, illustrando il collegamento dinamico dei moduli, la definizione dei vincoli e le strategie algoritmiche per la ricerca delle soluzioni.

- **Valutazione Predittiva e Modulazione Dinamica (ZenLearner):** Prima di istanziare il problema formale, il modulo ZenLearner agisce da gatekeeper valutando il potenziale carico cognitivo dell'utente. Viene calcolata una stima predittiva dello stress in base al monte ore di studio richiesto. Se tale proiezione supera la soglia massima di tolleranza definita nel profilo utente, il sistema interviene automaticamente sui parametri del modello. Questa fase di tuning dinamico applica restrizioni più severe ai vincoli operativi, riducendo il numero massimo di ore di studio consecutive e abbassando il tetto massimo di ore giornaliere, al fine di garantire un piano sostenibile.
- **Istanziamento del CSP e Iniezione dei Vincoli:** Successivamente alla calibrazione dei parametri, viene istanziata la struttura formale del Proble-

ma di Soddisfacimento dei Vincoli (CSP), definendo le variabili (le sessioni di studio pianificate) e i rispettivi domini temporali. A questa struttura di base vengono iniettati, in modo modulare, i vincoli fondamentali per la coerenza del piano:

- Assenza di sovrapposizioni: divieto di accavallamento temporale tra diverse sessioni.
- Carico consecutivo: rispetto del limite massimo di ore di studio continuative (valore calcolato dinamicamente in base all'indice di resilienza cognitiva).
- Carico giornaliero: rispetto del limite massimo di ore affrontabili in una singola giornata.
- Vincoli condizionali di scadenza: applicati dinamicamente solo se una specifica sessione è soggetta a una deadline.

Figura 14: Impatto Dinamico Dei Vincoli



Si evince come i vincoli tendano ad essere molto più rigidi e ristretti superata una soglia elevata di mental stress predetto, questo aiuta lo scheduler a ridurre proprio lo stress generato dal piano.

3.4 Algoritmo Utilizzato


La risoluzione del CSP è affidata a un risolutore che implementa un algoritmo di Backtracking basato su una ricerca in profondità (Depth-First Search - DFS). L'esplorazione dello spazio delle soluzioni avviene mediante chiamate ricorsive che tentano di costruire un'assegnazione completa e coerente.

Motivazione della scelta I Vincoli per ZenPlanner non sono penalità da minimizzare (come farebbe la "fitness" di un GA), ma regole booleane e imprescindibili. Un GA potrebbe fornire uno scenario "quasi perfetto" sfumando un vincolo (es. sovrapponendo parzialmente due materie per ottimizzare lo spazio). Il CSP, invece, rifiuta strutturalmente l'impossibile. Inoltre, in un Algoritmo Genetico, l'intero "individuo" deve essere completamente generato dalle mutazioni prima di poter essere valutato dalla funzione di fitness, sprecando istruzioni su rami palesemente morti fin dall'inizio. Il Solver CSP di ZenPlanner valuta l'accettabilità durante l'espansione nodo per nodo. Appena una variabile singola spezza una restrizione, l'algoritmo pota istantaneamente i successivi milioni di scenari derivati senza nemmeno esplorarli. Infine con l'utilizzo dell'euristica LCV è possibile "spalmare" gli orari in modo equo durante la settimana, cosa che sarebbe possibile in un GA solo con una funzione di calcolo varianza decisamente più pesante.

3.4.1 Euristiche Utilizzate


- **Minimum Remaining Values** Per ottimizzare le prestazioni computazionali e ridurre drasticamente i rami di ricerca infruttuosi, l'algoritmo impiega l'euristica MRV (Minimum Remaining Values). Prima di ogni nuova assegnazione, l'euristica analizza le variabili non ancora assegnate e seleziona quella che possiede il minor numero di valori coerenti rimasti nel proprio dominio, accelerando così la convergenza o anticipando il rilevamento di un vicolo cieco.

Figura 15: Influenza MRV



- Least Constraining Value** Per decidere quale slot temporale provare ad assegnare per primo a quella materia l'algoritmo fa uso di una euristica chiamata LCV (Least Constraining Value), dettagliatamente l'algoritmo prima di iterare sulle fasce orarie disponibili, il sistema conta dinamicamente quante ore di studio sono già state accodate per ogni singolo giorno della settimana all'interno del piano parziale. Dopodiché, ordina i blocchi temporali dando precedenza assoluta ai giorni attualmente più "scarichi".

Figura 16: Influenza LCV



3.4.2 BackTracking e Validazione

Il sistema si basa su una rigorosa verifica di coerenza locale durante la ricerca. Ad ogni passo, prima di procedere con il ramo ricorsivo successivo, lo stato dell'assegnazione parziale viene sottoposto a un modulo di validazione universale. Questo componente cicla su tutti i vincoli attivi e ne valuta il soddisfacimento. Se lo stato risulta coerente, la ricerca avanza in profondità; altrimenti, l'assegnazione viene annullata e si innesca il meccanismo di backtracking per esplorare alternative nello spazio di ricerca.

4 Integrazione Moduli

4.1 Strategia di Integrazione e Architettura Logica

La strategia adottata per l'integrazione dei due moduli principali del sistema, ZenLearner e ZenScheduler, si basa su un'architettura di tipo sequenziale a pipeline. Piuttosto che far operare i due algoritmi in parallelo o fonderli in un unico blocco computazionale, si è scelto di mantenere una rigorosa separazione delle responsabilità, facendo eseguire i moduli a cascata, l'uno in funzione dei risultati dell'altro. L'output del primo modulo diventa l'input fondamentale per l'esecuzione del secondo.

4.2 Comunicazione e Flusso dei Dati

Il processo di generazione del piano di studio si articola in una sequenza logica di passaggi che vede la comunicazione fra i due moduli:

1. **Integrazione del Profilo:** Il sistema aggrega i parametri relativi allo stile di vita e alle capacità di gestione dello stress dell'utente, costruendo un profilo contestuale.
2. **Stima del Carico Cognitivo:** Il modulo predittivo elabora i dati raccolti per calcolare un punteggio quantitativo, che rappresenta la proiezione dello stress generato dal carico di studio richiesto.
3. **Ricalibrazione dei Parametri:** Se l'analisi predittiva stima uno sforzo superiore alla soglia di tolleranza massima definita per quello specifico utente, l'orchestrazione interviene per mitigare il rischio di sovraccarico. Questa ricalibrazione adatta dinamicamente le regole di pianificazione:
 - (a) Riduce a una singola unità il limite massimo consentito per le sessioni di studio ininterrotte.
 - (b) Diminuisce proporzionalmente il tetto massimo di ore di studio allocabili in una singola giornata.
4. **Risoluzione Vincolata:** I nuovi parametri, resi più restrittivi dalla fase precedente, vengono formalizzati come vincoli stringenti e passati in input al risolutore DFS. L'algoritmo avvia quindi l'esplorazione dell'albero di ricerca operando all'interno di questi nuovi confini di sicurezza.

4.3 Orchestrazione tramite Dashboard

Sebbene i moduli ZenLearner e ZenScheduler costituiscano entità algoritmiche logicamente distinte nei rispettivi package, la loro esecuzione e integrazione a livello di sistema sono regolate da un orchestratore centrale, implementato tramite l'Application Layer (la Dashboard interattiva).

5 Considerazioni Finali

ZenPlanner è un'ottima iniziativa che previene il burnout studentesco tramite un'architettura ibrida Machine Learning (Random Forest) e un motore a vincoli (CSP). Invertendo il paradigma classico, il ML non genera il piano, ma funge da esperto del dominio e analizza i pattern psico-comportamentali latenti per definire i limiti di tolleranza allo stress. L'iniziativa funziona con sicurezza matematica offrendo un sistema interpretabile ed eticamente sicuro che supera la tipica opacità dei modelli puramente generativi o stocastici.

5.1 Ottimizzazioni possibili

Sul fronte logico di ZenScheduler, l'algoritmo Constraint Satisfaction Problem potrebbe beneficiare dell'integrazione di euristiche di ricerca più avanzate. Sebbene il meccanismo di backtracking si comporti egregiamente su orizzonti temporali standard, per pianificazioni a lungo termine o con vincoli utente estremamente stringenti sarebbe opportuno implementare tecniche di inferenza come l'Arc Consistency (es. AC-3) o un 'Forward Checking' più aggressivo. Queste ottimizzazioni sfoltirebbero preventivamente i domini dell'albero di ricerca, riducendo sensibilmente la complessità computazionale e i tempi di elaborazione per la generazione del calendario.

5.2 Sviluppi Futuri

- **Continuous Learning (Reinforcement Loop):** Creare un circuito (feedback loop) in cui lo studente, a fine settimana, valuta il "percepito vs assegnato" del piano generato. Questi dati di scostamento andrebbero ad arricchire il dataset originario per eseguire una fase di ri-addestramento schedulata del Random Forest.
- **Retrain Su Nuovi Dati:** L'attuale dataset presenta del rumore e l'errore irriducibile dei dati non aiuta il modello. Una soluzione sarebbe effettuare il retrain del modello su un nuovo set di dati aggiornato per garantire minore rumore e più accuratezza.
- **Agenti LLM Negoziali per gli Unsolvable States:** Qualora le combinazioni richieste (troppe materie e troppo poco tempo) unita a un alto stress predittivo creino un problema non risolvibile (il CSP ritorna array nullo), si potrebbe inglobare un Agente LLM intermedio. Questo Agente leggerebbe la matrice dei fallimenti e, conversando con l'utente, "negozierebbe" l'impossibilità matematica: "Non posso pianificare in sicurezza queste 4 materie entro giovedì a causa del tuo stress in soglia rossa; ti consiglio di rimandare la Materia B, sei d'accordo?".